


MM-TKGF

MU-ty
2026.3.17

2个问题

挑战：需要从局部结构和全局时序两个视角筛选事实

- 如何从局部结构和全局时序角度有效识别与查询相关的事实？




影响：冗余降低了模型性能和训练效率

2个问题

挑战：仅依靠结构和时序不足以区分，需要多模态辅助

- 如何利用多模态信息来区分相似实体？



解决：利用图像和文本提供差异化特征

related work

- 时间知识图谱推理

- 插值方法(Interpolation)

- 目标: **在历史时间戳上补全缺失事实**

- 方法思路: 将静态KG嵌入方法扩展为时序版本

- 局限性: 只能预测历史缺失事实, 难以有效预测未来事实, 因为无法充分利用时序动态

- 外推方法(Extrapolation)

- 目标: **利用历史观测推断未来可能发生的事实**

- 方法思路: 将TKG视为快照序列, 沿时间轴提取时序模式

- 研究空白: 上述方法大多 struggles to forecast unseen entities, 且未利用多模态辅助信息增强TKG推理

插值相关研究

- TTransE (Jiang et al., 2016): 在TransE基础上加入时序表示
- TTransH (Dasgupta et al., 2018): 将实体和关系投影到时间特定的超平面
- DE-SimpleE (Goel et al., 2020): 利用时变词嵌入生成时序特定实体表示
- ChronoR (Sadeghian et al., 2021): 基于RotatE的旋转方法, 通过缩放和旋转表示时序动态
- RTGE (Xu et al., 2022): 结合时序平滑性度量生成鲁棒时序嵌入

外推相关研究

- GCRN (Seo et al., 2018): 集成GNN层与RNN, 联合捕获结构依赖和时序动态
- RE-NET (Jin et al., 2020): 结合R-GCN邻居编码器与RNN模块
- CEN (Li, Guan, et al., 2022): 使用长度感知卷积网络适应不同长度的快照序列
- TLogic (Liu et al., 2022): 符号方法, 从历史事实中提取时序逻辑规则进行推理
- LogCL (Chen et al., 2024): 采用局部-全局历史感知框架, 结合对比学习增强抗噪能力
- Re-Temp (Wang, Han, & Poon, 2023): 设计跳过的信息流机制, 动态过滤不必要信息

related work

- 多模态知识图谱推理
 - 传统KG局限：仅包含结构信息（关系、实体、事实）
 - MMKG优势：将KG结构与多模态辅助信息（文本、图像）结合，丰富实体表示
 - 数据演进：
 - 单模态MMKG：如IMGPedia（仅图像）、FB-Des（仅文本描述）
 - 多模态MMKG：如WN9-IMG-TXT、FB-IMG-TXT（图像+文本）
 - 质量提升：Richpedia设计检索模型过滤异常图像，确保图像与实体高度相关

related work

- 多模态融合策略

- 1、早期融合策略（简单拼接/相加）

- 方法：直接对多模态特征向量进行concatenation或addition
 - 局限：无法过滤模态间噪声，会损害实体表示质量

- 2. 自适应权重机制

- 注意力机制：如MFB/MFH (Yu et al., 2018) 聚合各模态的重要信息
 - 细粒度融合：如MCAN (Yu et al., 2019) 使用自注意力机制动态融合多模态特征
 - 门控机制：如MMKGR (Zheng et al., 2023) 设计门控注意力机制过滤模态内/间噪声
 - 关系引导：(Zhang, Chen et al., 2024) 使用关系引导融合模块解决模态分布不平衡

- 3. 问题

- 所有上述MMKG方法都假设实体是静态的，无法处理动态时序场景
 - 无法将静态多模态特征与动态实体时序表示进行有效融合

related work

- 静态多模态知识图谱推理
 - 核心缺口：多模态信息 + 时序建模的结合在现有工作中完全缺失
 - 最相关研究：仅Deng et al. (2020)将文本描述用于事件KG，Liu et al. (2023)在POI推荐中使用MMTKG，但均未探索MMTKG预测问题

背景

- TKG 时序知识图谱推理

{ 定义：包含时间戳四元组
作用：预测未来发生的事实
局限：仅利用结构化和时序信息，忽略多模态辅助信息

- MMKG 多模态知识图谱推理

{ 定义：传统知识图谱 + 多模态信息（文本、图像）
局限：仅适用静态场景，无法同时利用时序场景
问题：缺少动态时序 + 多模态融合推理方法

预备知识与定义

Notations	Descriptions
$\mathcal{G}$	An MMTKG
$\mathcal{G}_t$	A snapshot of MMTKG at timestamp t
$\mathcal{E}$	An MMTKG's entity set
$\mathcal{E}_t$	An MMTKG's entity set at timestamp t
$\mathcal{R}$	An MMTKG's relation set
$\mathcal{R}_t$	An MMTKG's relation set at timestamp t
$\mathcal{F}$	An MMTKG's fact set
$\mathcal{F}_t$	An MMTKG's fact set at timestamp t
$\mathcal{M}_e$	An MMTKG's multi-modal feature vector set
$\mathcal{M}_e^t$	An MMTKG's textual feature vector set
$\mathcal{M}_e^i$	An MMTKG's image feature vector set
$\vec{x}_{e,t}$	Learnable structural embedding of entity e at timestamp t
$\vec{h}_{e,t}$	Learnable temporal embedding of entity e at timestamp t
$\vec{m}_e$	Learnable multi-modal embedding of entity e at timestamp t
$\vec{m}_e^t$	Pre-trained textual embedding of entity e
$\vec{m}_e^i$	Pre-trained image embedding of entity e
$\vec{z}_{e,t}$	Learnable unified embedding of entity e at timestamp t
m	Observation time window(s)
d	Embedding dimension(s)
d_t	Pre-trained textual embedding dimension(s)
d_i	Pre-trained image embedding dimension(s)

预备知识与定义

• 定义 I：多模态时序知识图谱

定义 I（多模态时序知识图谱）。现有的时序知识图谱（TKG）通常仅包含图结构信息，我们通过引入一种将多模态辅助数据与基础图结构相结合的新型 TKG 来解决这一局限性。具体而言，作为传统 TKG 的扩展，MMTKG（记为 $\mathcal{G} = \{\mathcal{E}, \mathcal{R}, \mathcal{F}\}$ ）可以形式化为快照序列 $\{\mathcal{G}_1, \mathcal{G}_2, \dots, \mathcal{G}_t, \dots, \mathcal{G}_n\}$ 。每个快照 $\mathcal{G}_t = \{\mathcal{E}_t, \mathcal{R}_t, \mathcal{F}_t\}$ 是时间戳 t 下的有向异构图，其中 $\mathcal{E}_t$ 表示关联了多模态特征的实体集， $\mathcal{R}_t$ 是关系集， $\mathcal{F}_t$ 表示时间戳 t 下的事实集。多模态时序事实的形式表示为一个四元组 (e_i, r, e_j, t) ，其中 $e_i, e_j \in \mathcal{E}$ 和 $r \in \mathcal{R}$ 表示主体实体 e_i 在时间戳 t 通过关系 r 连接到客体实体 e_j 。

• 定义 II：多模态辅助特征

MMTKG 的多模态辅助特征是一系列预训练特征，这些特征提取自各种实体属性，例如文本描述、字面值、地理坐标或来自多媒体源的图像。对于每个实体 e ，其多模态特征表示为 m_e ，进而表示为一个 d 维向量 $\vec{m}_e = f(\vec{m}_e^t, \vec{m}_e^i)$ 。具体而言，

$\vec{m}_e \in \mathcal{M}_e$ 是从两种类型的多模态数据（即文本和图像）中学习得到的，其中 $\vec{m}_e^t \in \mathbb{R}^{d_t}$ 表示文本特征向量， $\vec{m}_e^i \in \mathbb{R}^{d_i}$ 表示图像特征向量， $f(\cdot)$ 指代一种多模态融合方法，而 $\mathcal{M}_e = \{\vec{m}_e | e \in \mathcal{E}\}$ 则是所有实体的多模态特征向量集合。

预备知识与定义

- 问题定义
- 本文侧重于基于历史快照从受损的四元组中推断出缺失的主语实体 s 或宾语实体 o 。

问题（多模态时序知识图谱预测）。给定未来时间戳的查询，即 $(?, r, o, t)$ 或 $(s, r, ?, t)$ ，连同历史快照序列 $\{G_1, G_2, \dots, G_{t-1}\}$ 和观测时间窗口 m ，所提出的模型根据历史观测 $\{G_{t-m+1}, \dots, G_{t-1}\}$ 预测缺失的实体（主语或宾语）。以宾语实体预测为例：

$$p(o|s, r, t; G_{t-m+1:t-1}) = p(o|s, r, t; \mathcal{E}_{t-m+1:t-1}, \mathcal{R}_{t-m+1:t-1}, \mathcal{M}_e, F_{t-m+1:t-1}) \quad (1)$$

延续图 1 中的示例，给定历史快照序列 $G = \{G_a, G_b, G_c, G_d, G_e\}$ 、观测时间窗口 $m = 4$ 以及相应的实况 $\{(\text{美国}, \text{咨询}, \text{小布什}, 2014-03), (\text{美国}, \text{咨询}, \text{老布什}, 2014-03), (\text{奥巴马}, \text{访问}, \text{欧盟}, 2014-05), (\text{老布什}, \text{访问}, \text{欧盟}, 2014-05), (\text{小布什}, \text{访问}, \text{欧盟}, 2014-05), (\text{奥巴马}, \text{咨询}, \text{印度}, 2014-07)\}$ ，所提出的模型将预测受损四元组（美国，咨询，？，2014-11）中缺失的元素，该四元组可能发生在未来的时间戳。

预备知识与定义


- 问题定义

- 任务：多模态时序知识图谱预测
- 输入：未来时间戳查询($?, r, o, t$)或($s, r, ?, t$), 历史快照序列 $G_{\{t-m+1:t-1\}}$
- 输出：预测缺失的主体或客体实体
- 示例：给定历史事实，预测2014US

MM-TKGF模型架构



方法论



AMFE模块 (Attention-based Multi-faceted Encoder)

基于注意力的多面编码器

- 解决问题 I (从结构和时序两个角度识别查询相关事实)、学习实体时序特征
- 组件 $\begin{cases} AGNF & (\text{Attentive Graph Neighbour Encoder}) \\ ATE & (\text{Attention - based Temporal Encoders}) \end{cases}$


AMFE模块 (Attention-based Multi-faceted Encoder)

- *AGNF*

功能：建模MMTKG快照内的结构依赖

核心：关系图卷积 (PGCN) + 查询依赖注意力

作用：动态聚合最重要的结构信息，生成实体和关系的结构表征



AMFE模块 (Attention-based Multi-faceted Encoder)

- *AGNF*

实体结构: $\chi_{e,\tau} = \{ \vec{x}_{e,t} | e \in \mathcal{E}, t \in \tau \}$

嵌入初始化

关系结构: $\chi_{r,\tau} = \{ \vec{x}_{r,t} | r \in \mathcal{R}_t, t \in \tau \}$

以示例查询($s, r, ?, t$)为例介绍结构编码器, 其中? 表示缺失元素。

该过程从查询主体实体 s 及其在时间戳 t 的一个相连关系边开始。

输入:

实体嵌入: $\vec{x}_{s,t}^0 = W_{0,s} \vec{e}_s, \forall t \in \mathcal{T}, \mathcal{T} = \{1, 2, \dots, T\}$

关系嵌入: $\vec{x}_{r,t}^0 = W_{0,r} \vec{e}_r, \forall t \in \mathcal{T}, \mathcal{T} = \{1, 2, \dots, T\}$

$\vec{e}$ 表示独热向量, W_0 表示嵌入矩阵

AMFE模块 (Attention-based Multi-faceted Encoder)

- *AGNF*

邻域扩展、候选集构建

给定查询 $(s, r, ?, t)$ ，创建一个自环四元组 (s, r_0, s, t) 并将其添加到邻居列表 L_s^1 中，其中 r_0 表示自环关系。

对于每个对象实体 $p \in L_s^l$ ，随后会采样 i 个相邻关系 $\{j_0^l, j_1^l, \dots, j_i^l\} \in t$ 及其对应的相连实体 $\{q_0^l, q_1^l, \dots, q_i^l\}$ 。

这些抽样的关系-实体对进一步形成四元组，这些四元组被假定与查询相关，并被添加到邻居列表 L_s^l 中。

$$L_s^l = \{(p, j, q, t) | (e_n, r_n, p, t) \in L_s^{l-1}\} \cup \{s, r_0, s, t\}$$

其中 l 表示扩展层的数量， $l=1$ 对应于为查询 s 聚合单跳邻居， $\{(e_n, r_n, p, t)\}$ 表示存储在邻居列表 L_s^{l-1} 中的四元组集合，其对象实体进一步用作下一次扩展的主体实体。

AMFE模块 (Attention-based Multi-faceted Encoder)

- *AGNF*

查询依赖注意力分数

为了动态加权 L_s^l 中采样的邻居，通过以下公式计算与查询相关的注意力得分，从而能够基于邻居与查询的相关性进行自适应聚合。

$$e_{p,j,q}^l = \mathbf{W}_{sub}^l (\vec{x}_{p,l}^{l-1} \parallel \vec{x}_{s,l}^{l-1} \parallel \vec{x}_{r,l}^{l-1} \parallel \vec{x}_{j,l}^{l-1}) \cdot \mathbf{W}_{obj}^l (\vec{x}_{q,l}^{l-1} \parallel \vec{x}_{s,l}^{l-1} \parallel \vec{x}_{r,l}^{l-1} \parallel \vec{x}_{j,l}^{l-1})$$

向量拼接+双矩阵内积

其中， $e_{p,j,q}^l$ 是对应于查询 $(s, r, ?, t)$ 的扩展四元组 (p, j, q, t) 的注意力分数， $\parallel$ 表示拼接操作， $\mathbf{W}_{sub}^l$ 和 $\mathbf{W}_{obj}^l$ 表示捕获查询与扩展四元组之间结构依赖关系的权重矩阵。随后，通过soft-max函数计算每个邻域的归一化注意力分数 $w_{p,j,q}$ ，如下所示

$$w_{p,j,q} = \frac{\exp(e_{p,j,q}^l)}{\sum_{(p,j,q,t) \in L_s^l} \exp(e_{p,j,q}^l)}$$

归一化

AMFE模块 (Attention-based Multi-faceted Encoder)

- *AGNF*

邻域剪枝

在计算注意力分数之后，我们分析哪些邻居能提供有价值的结构信息。随着扩展的进行，邻居列表可能会存储注意力分数较低的实体，从而增加AGNE层的计算成本。为了缓解这一问题，我们通过保留k个分数最高的邻居来剪枝冗余邻居（即那些贡献较少结构信息的邻居）。具体来说，邻居会按照注意力分数从高到低排序，然后使用一个截断值k来确定应该保留多少个邻居，以便为查询提供有价值的结构信息。

$$L_s^l = \{(p, j, q, t) \in \{L_s^l \setminus \{s, r_0, s, t\}\} \mid \mathbb{1}(\text{rank}(w_{p,j,q} | L_s^l) < k)\} \cup \{(s, r_0, s, t)\}$$

其中 $\mathbb{1}$ 表示二进制指示函数，函数 $\text{rank}(\cdot)$ 表示四元组在邻居列表 L_s^l 中的位置，该列表是根据归一化注意力分数 $w_{p,j,q}$ 按降序排序的。值得注意的是，除了单跳邻居外，结构信息还包含多跳（例如2跳或更多）的更远邻居。为了获得更多的结构依赖关系，AGNE通过迭代应用该过程1次来聚合1跳邻居实体。

AMFE模块 (Attention-based Multi-faceted Encoder)

- *AGNF*

注意力加权聚合邻域特征+残差链接

通过应用上述带有自适应边剪枝的注意力机制，AGNE从实体s的采样邻居中提取出最重要的结构依赖关系。随后，邻居信息被聚合，以通过给定的方程式迭代更新s的结构表示。

$$\vec{x}_{s,t}^l = \sigma \left(\sum_{j_0, \dots, j_l \in R_l} \sum_{(p,j,q,t) \in L_s^l \setminus \{(s,r_0,s,t)\}} \frac{1}{|j_i|} w_{p,j,q} \mathbf{W}_{att,i}^l \vec{x}_{p,t}^{l-1} + \mathbf{W}_s^l \vec{x}_{s,t}^{l-1} \right)$$


其中 $\vec{x}_{p,t}^{l-1}$ 是第 $l-1$ 层中邻居 p 的结构表示， $\sigma(\cdot)$ 表示 LeakyReLU 激活函数 $\mathbf{W}_{att,i}^l$ 表示第 l 层的特定关系转换矩阵， $\mathbf{W}_s^l$ 表示第 l 层的转换矩阵，并且矩阵 $\mathbf{W}_{att,i}^l$ 、 $\mathbf{W}_s^l$ 在不同时间戳是共享的。实体 s 在时间戳 t 的最终结构表示 $\vec{x}_{s,t}^l$ 是通过将 $\vec{x}_{s,t}^{l-1}$ 经过一个全连接层得到的。

该单元捕捉了多模态时序知识图谱 (MMTKG) 快照中的结构依赖关系。为了更全面地描述实体，对其在多个 MMTKG 快照中的演变进行建模至关重要。因此，结构表示随后会被输入到 ATE 模块中，以提取时间动态特征。

AMFE模块 (Attention-based Multi-faceted Encoder)

- *AGNF*

对于查询 $(s, r, ?, t)$, AGNE 从主体实体 s 出发, 找到在当前时间戳 t 与之相连的所有边和邻居



<https://ucn1tfq3id0v.feishu.cn/wiki/WYcLwFenAiTI3KkmDM1cwKwenhb>


AMFE模块 (Attention-based Multi-faceted Encoder)

- ATE

功能：捕获MMTKG中的时序动态

核心：自注意力机制

作用：突出查询相关的时序动态，细化实体时序表征



AMFE模块 (Attention-based Multi-faceted Encoder)


• ATE

ATE的时序表示初始化分两种场景，取决于当前时间戳 t 是否为第一个快照 ($t = 1$) :


- 若 $t = 1$ (无历史快照) : 直接将AGNE输出的当前结构表示作为初始时序表示, 即 $\vec{h}_{s,1} = \vec{x}_{s,1}$;
- 若 $t > 1$: 历史快照 $\mathcal{G}_{t-m+1}$ 到 $\mathcal{G}_{t-1}$ 中, 实体 s 的时序表示已通过前序迭代生成, 直接作为历史输入 $\vec{h}_{s,t-m+1}, \dots, \vec{h}_{s,t-1}$ 。

Historical Representations = $\{\vec{h}_{s,\tau} \mid \tau \in [t-m+1, t-1]\}$

$$\vec{h}_{s,t} = \sum_{\tau=0}^m \beta_{s,t,t-\tau} \cdot (\vec{h}_{s,t-\tau} W_v) + \vec{x}_{s,t}$$



$$u_{s,t,t-\tau} = \frac{(\vec{x}_{s,t} W_q) \cdot (\vec{h}_{s,t-\tau} W_k)^\top}{\sqrt{d}}$$



$$\gamma_{s,t,t-\tau} = \begin{cases} 1 & \text{if entity } s \text{ is present at timestamp } t - \tau \\ 0 & \text{otherwise} \end{cases}$$


$$\beta_{s,t,t-\tau} = \frac{\exp(u_{s,t,t-\tau} \cdot \gamma_{s,t,t-\tau})}{\sum_{i=0}^m \exp(u_{s,t,t-i} \cdot \gamma_{s,t,t-i})}$$

TGME模块 (Temporalaware Gated Multi-modal Fusion Module)

- 解决问题 II (融合多模态信息与实体时序表征) 并过滤模态间的噪声, 实现细粒度融合
- 多模态数据准备
 - 文本信息: 实体属性、描述、数值数据
 - 图像信息: 实体相关图片, 需过滤异常和重复
- 多模态特征提取
 - 文本特征: *Doc2vec*预训练模型 $\rightarrow d_t$ 维向量
 - 图像特征: ResNet (去除最后一层) $\rightarrow d_i$ 维向量
 - 特征拼接: $\sigma(\mathbf{W}_m(\mathbf{W}_t\vec{m}_e^t \parallel \mathbf{W}_i\vec{m}_e^i) + \vec{b}_m) \rightarrow d$ 维统一表征
- 门控制融合单元
 - 设计: 中间融合, 避免早期融合破坏时序表征
 - 门控机制: $g_t = \sigma(\mathbf{W}_g\vec{m}_e + \vec{b}_g)$
 - 融和公式: $\vec{z}_{e,t} = (1 - g_t)\vec{h}_{e,t} + g_t\vec{m}_e$
 - 优势: 自动平衡时序表征和多模态特征比例, 过滤噪声

TGME模块 (Temporalaware Gated Multi-modal Fusion Module)

<https://ucn1tfq3id0v.feishu.cn/wiki/WYcLwFenAiTI3KkmDM1cwkWenhb>



训练目标

- 解码器设计 $\left\{ \begin{array}{l} \text{使用 } ConvTransE \text{ 作为评分标准} \\ \text{混合解码器 } \phi(s, r, o, t) = \alpha \cdot \sigma(\vec{h}_{o,t} ConvTransE(\vec{h}_{s,t}, \vec{x}_{r,t})) + (1 - \alpha) \cdot \sigma(\vec{z}_{o,t} ConvTransE(\vec{z}_{s,t}, \vec{x}_{r,t})) \\ \alpha: \text{ 可学习参数, 平衡两个解码器的分支} \end{array} \right.$

- 损失函数 $\left\{ \begin{array}{l} \text{客体预测损失 } \mathcal{L}_1 = - \sum_t \sum_{(s,r) \in \mathcal{G}} \mathbb{1}_{(s,r,o,t) \in \mathcal{G}} \log p(o|s, r, t; \mathcal{G}_{t-m:t-1}) \\ \text{主体预测损失 } \mathcal{L}_2 = - \sum_t \sum_{(o,r) \in \mathcal{G}} \mathbb{1}_{(s,r,o,t) \in \mathcal{G}} \log p(s|o, r, t; \mathcal{G}_{t-m:t-1}) \\ \text{总损失 } \mathcal{L} = \mathcal{L}_1 + \mathcal{L}_2 \end{array} \right.$

实验设计

- 研究问题
 - MM-TKGF在MMTKG预测任务上的整体性能
 - AMFE模块中不同结构编码器和时间编码器的影响（消融实验）
 - 不同多模态信息和融合策略的影响
 - 不同多模态预训练模型和噪声级别的影响
 - 超参数敏感性和模型效率

Dataset	$ \mathcal{E} $	$ \mathcal{R} $	$ \mathcal{F} $	$ \mathcal{T}_g $	$ \mathcal{T}_s $	ρ	$ \mathcal{M}_e^t $	$ \mathcal{M}_e^i $	#Training	#Validation	#Test
MMICEWS'14	10 261	235	264 958	24 h.	365 days	725.9	10 261	7294	211 268	27 689	26 001
MMICEWS'18	7665	229	297 663	24 h.	365 days	814.8	7665	5764	238 636	29 360	29 397
MMICEWS'05-15	14 432	246	603 090	24 h.	4017 days	150.1	14 432	10 099	482 314	61 520	59 256

实验设计

- 实验装置

- 数据集 MMTKG数据集，统计信息：实体数、关系数、事实数、时间粒度

- 基线模型

- $\left\{ \begin{array}{l} \text{Static模型 (静态KG模型) : 仅考虑结构信息, 忽略时序和多模态} \\ \text{Multi-modal模型 (多模态KG推理) : 考虑结构 + 多模态, 但是是静态的} \\ \text{Temporal模型 (时序KG推理) : 考虑时序 + 结构, 但忽略多模态} \end{array} \right.$

实验结果和分析

- 主要性能对比
 - MM-TKGF在三个数据集上均显著超过了所有基线
 - MRR、Hits@135指标最优
 - 多模态带来显著提升

实验结果和分析

- 消融实验
 - 结构编码器变体
 - 对比不同AGNE配置，有无注意力、不同剪枝策略
 - 验证AGNE设计的有效性
 - 时间编码器变体
 - 对比不同ATE配置，不同注意力机制
 - 验证时序感知设计的必要性

实验结果和分析

- 多模态融合策略
 - 全模态融合效果最优（文本、图像、图结构）
 - 中间融合优于早期、晚期融合
 - 门控机制有效过滤模态间噪声

实验结果和分析

- 预训练模型与噪声分析
 - Doc2vec和ResNet作为特征提取器表现良好
 - 模型对一定程度的噪声具有鲁棒性

实验结果和分析

- 超参数敏感性

关键超参数 { 观测时间窗口 m : 影响历史信息利用范围
扩展层数 l : 影响图卷积深度
截断数 k : 影响邻居聚合数量
学习率 η : 影响收敛速度和稳定性
快照数 n : 影响时序建模粒度

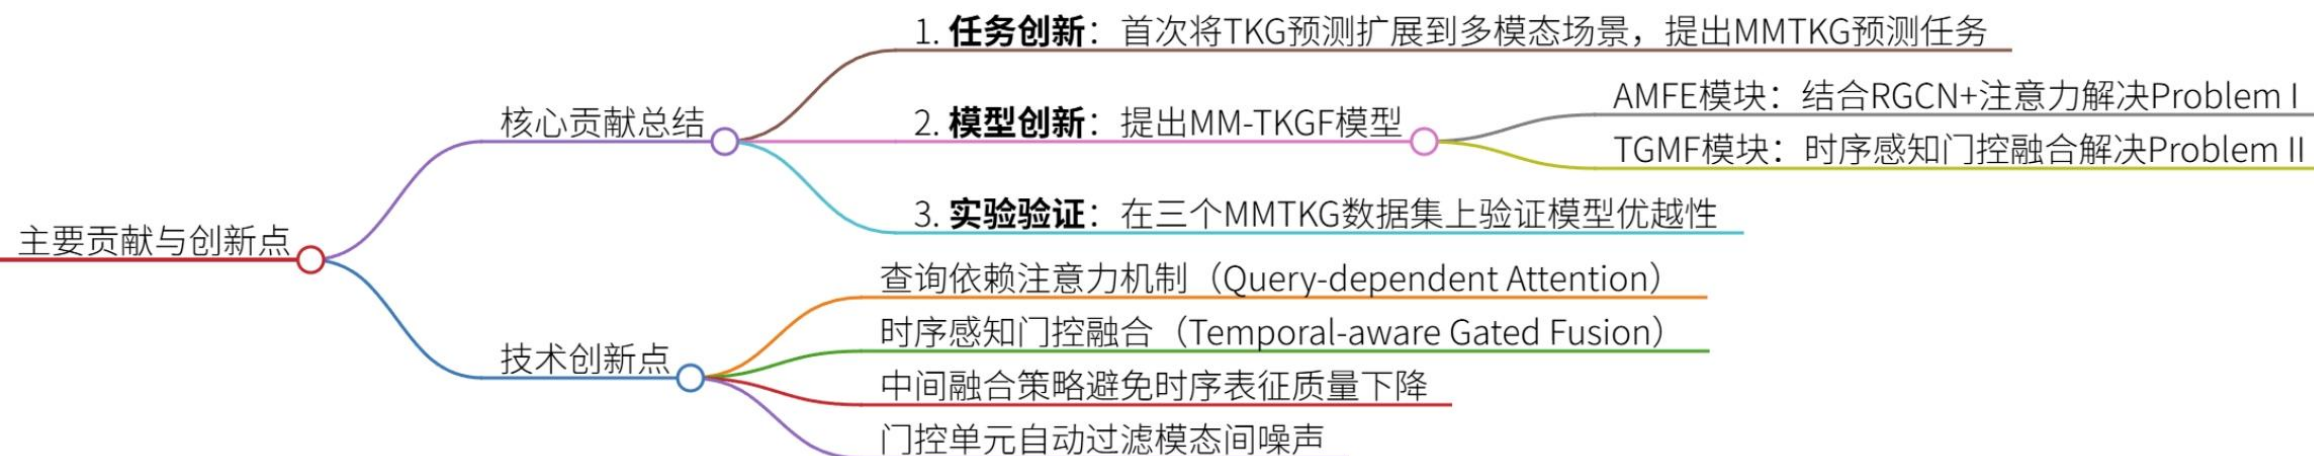
实验结果和分析

- 定性分析
 - Table5：展示MM-TKGF及其变体在具体查询上的Top3预测、验证各模块对预测结果的实际影响
 - 跨模态嵌入可视化（Fig19）：结构、时序、文本、图像、统一表征，验证多模态融合学习了有意义的联合表征

实验结果和分析

- 效率 (Fig20)
 - 训练时间与推理时间对比
 - VRAM占用与MRR的内存效率分析
 - MM-TKGF在性能和效率之间的平衡

贡献和创新



细节总结

- AGNE算法
 - 输入：MMTKG历史快照序列，观测窗口 m
 - 过程：迭代构造邻居列表，计算注意力分数，剪枝，更新实体结构表征
 - 输出：实体结构表征
- ATE算法
 - 输入：MMTKG历史快照序列，观测窗口 m
 - 过程：遍历查询，在时间窗口内计算自注意力，更新实体时序表征
 - 输出：实体时序表征集合
- 特征提取
 - Doc2vec：学习文本分布式表示
 - ResNet：提取图像视觉特征
 - 线性变换：将高维多模态特征投影到统一维度
- 解码器
 - ConvTransE：卷积版的TransE，适合KG嵌入解码
 - 混合解码：平衡图结构信息与多模态信息

总结

- 知识图谱
 - 一种结构化的知识库，传统知识图谱是静态的，以三元组 (主体实体, 关系, 客体实体) 为基本单元，比如 (美国, 咨询, 老布什)
- 时序
 - 给知识图谱加入时间维度
 - 是一系列按时间排序的静态KG快照，用四元组 (主体, 关系, 客体, 时间戳) 表示，比如 (奥巴马, 咨询, 印度, 2014-07)
 - 核心任务：插值、外推
- 多模态
 - 在知识图谱的结构化数据之外，融合文本、图像